



دانشگاه علم و صنعت
دانشکده مهندسی کامپیوتر

یادگیری از روی نمونه داده ماشین بردار پشتیبان

«هوش مصنوعی: رهیافتی نوین»، فصل ۱۸

مدرس: آرش عبدی هجراندوست

نیم سال دوم ۱۴۰۱-۱۴۰۲

ماشین بردار پشتیبان

Support Vector Machine - SVM

❖ ابزاری برای یادگیری با نظارت

❖ خیلی وقت‌ها اولین انتخاب می‌تواند باشد، اگر دانش زمینه‌ای خاصی از مساله که ما را به سمت روش خاصی سوق دهد، نداشته باشیم.

❖ ابزار دسته‌بندی است، نه هر یادگیری‌ای (برخلاف شبکه عصبی)

ویژگی‌های مشخصه

❖ خط جداکننده‌ای بر اساس ایجاد بیشترین حاشیه پیدا می‌کند

❖ تعمیم بالا

❖ ابرصفحه‌ای خطی ایجاد می‌کند (برای جداکردن داده‌ها).

❖ هرچند با استفاده از «ترفند هسته» داده‌ها به فضای دیگری (احتمالا با ابعاد بزرگتر) نگاشت می‌شوند.

❖ با این ترفند، اگر داده‌ها در فضای اولیه به صورت خطی، جداپذیر نباشند، احتمالا در فضای (فضای هسته) به صورت خطی جداپذیر خواهند بود.

❖ روشی (تقریبا) بدون پارامتر است.

❖ درد پارامتر کشیده‌ها معنای جمله فوق را می‌فهمند!

❖ پارامترهای آزاد یک الگوریتم، میخ‌های تابوتش هستند.


❖ SVM در عوض، بخشی از خود نمونه‌ها را ذخیره می‌کند.

❖ در بدترین حالت، تمام نمونه‌ها را

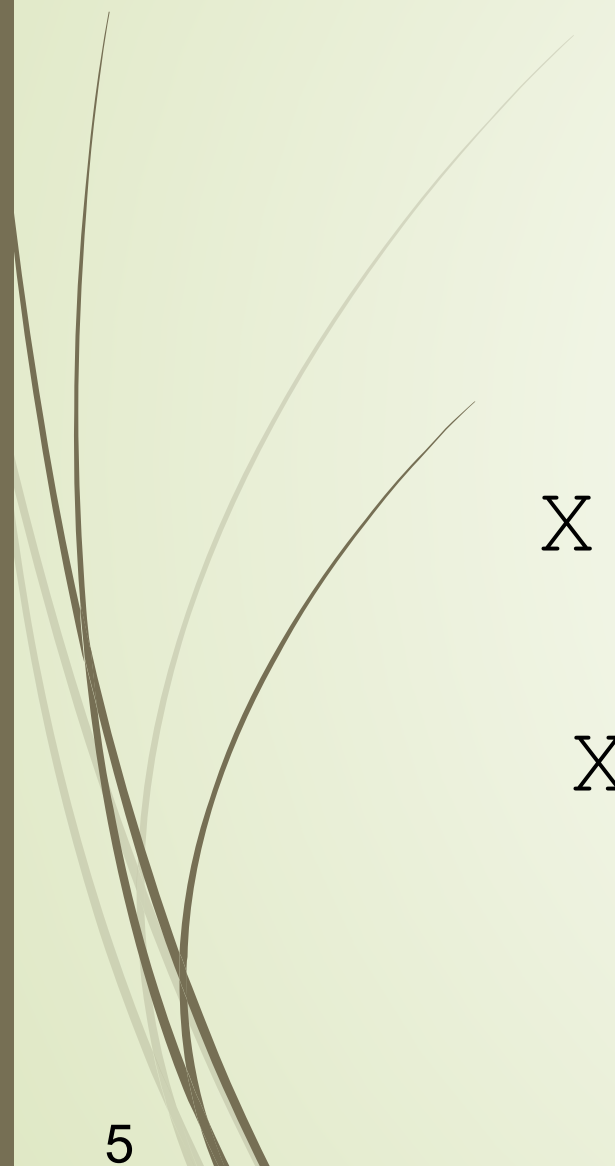
❖ ولی معمولا درصد بسیار پایینی از آنها را

❖ مثلا نمونه داده‌هایی به تعداد چند برابر ابعاد داده‌ها، نگهداری می‌شود.

کدام خط جدا کننده؟



دقت پیشینه؟



X X X
X X
X X X
X X


O O O
O O
O O O
O O

دقت بیشینه؟

X X X
X X
X X X
X X

O O O
O O
O O O

دقت پیشینه؟





بیشتر از دقت بیشینه؟


X X X
X X
X X X
X X

O O O
O O
O O O


نویز و تعمیم




آیا خطوط با بیشترین دقت مناسب هستند؟



اگر نویز بیشتر شود؟ (نه فقط نویز)




حاشیه امن!



کدام خط جداکننده؟


رگرسیون Logistic

یکی از خطوط را پیدا می کند
تمام نمونه داده ها (نقاط) در یافتن آن تاثیر دارند



SVM

برخی از نمونه ها در تعیین خط جداکننده مهم
تر هستند (باید باشند)
← تعمیم بیشتر



یافتن خط جداکننده

- ❖ SVM تلاش می کند قدرت تعمیم را افزایش دهد
- ❖ جدا کنندگی بر اساس ایجاد بیشترین حاشیه (Margin)
- ❖ حاشیه: دوبرابر فاصله خط تا نزدیکترین نقطه
- ❖ مساله دو کلاسه (+۱ و -۱)
- ❖ خط جدا کننده: $\{x : w.x + b = 0\}$
- ❖ می توان با کمک روش نزول در راستای گرادیان پارامترهای خط (w, b) را به گونه ای یافت که حاشیه بیشینه گردد، و تمام داده ها هم (در صورت امکان) به درستی جدا شوند.
- ❖ اما روش محاسباتی دیگری برای حل مساله فوق وجود دارد که در ادامه خلاصه آن بیان می شود

حل مسئله برای حالت دو بعدی

❖ نمونه های آموزشی

$$x \in \mathbb{R}^n$$

$$y \in \{-1, 1\}$$

❖ تابع تصمیم گیری

$$\text{sign}(\langle w, x \rangle + b)$$

$$w \in \mathbb{R}^n$$

$$b \in \mathbb{R}$$

❖ ابر صفحه

$$\langle w, x \rangle + b = 0$$

$$w_1 x_1 + w_2 x_2 \dots + w_n x_n + b = 0$$


❖ میخواهیم مقادیر w, b را به گونه ای پیدا کنیم که:

❖ نمونه های آموزشی را بدقت دسته بندی کند

❖ با این فرض که داده ها بصورت خطی جدا پذیر باشند

❖ حاشیه را حداکثر نماید

حل مسئله برای حالت دو بعدی



بردار w بر هر دو صفحه مثبت و منفی عمود خواهد بود.

❖ فاصله خط جداکننده از مبدا برابر است با

❖ فاصله نمونه ای مثل x از خط جدا کننده برابر است با

$$\frac{|f(x)|}{\|w\|} = \frac{|wx+b|}{\|w\|}$$

What is the distance of a point \mathbf{x} to the hyperplane \mathcal{H} ?

Consider some point \mathbf{x} . Let \mathbf{d} be the vector from \mathcal{H} to \mathbf{x} of minimum length. Let \mathbf{x}^P be the projection of \mathbf{x} onto \mathcal{H} . It follows then that:

$$\mathbf{x}^P = \mathbf{x} - \mathbf{d}.$$

\mathbf{d} is parallel to \mathbf{w} , so $\mathbf{d} = \alpha \mathbf{w}$ for some $\alpha \in \mathbb{R}$.

$\mathbf{x}^P \in \mathcal{H}$ which implies $\mathbf{w}^T \mathbf{x}^P + b = 0$

$$\text{therefore } \mathbf{w}^T \mathbf{x}^P + b = \mathbf{w}^T (\mathbf{x} - \mathbf{d}) + b = \mathbf{w}^T (\mathbf{x} - \alpha \mathbf{w}) + b = 0$$


$$\text{which implies } \alpha = \frac{\mathbf{w}^T \mathbf{x} + b}{\mathbf{w}^T \mathbf{w}}$$

The length of \mathbf{d} :

$$\|\mathbf{d}\|_2 = \sqrt{\mathbf{d}^T \mathbf{d}} = \sqrt{\alpha^2 \mathbf{w}^T \mathbf{w}} = \frac{|\mathbf{w}^T \mathbf{x} + b|}{\sqrt{\mathbf{w}^T \mathbf{w}}} = \frac{|\mathbf{w}^T \mathbf{x} + b|}{\|\mathbf{w}\|_2}$$

$$\text{Margin of } \mathcal{H} \text{ with respect to } D: \gamma(\mathbf{w}, b) = \min_{\mathbf{x} \in D} \frac{|\mathbf{w}^T \mathbf{x} + b|}{\|\mathbf{w}\|_2}$$

By definition, the margin and hyperplane are scale invariant: $\gamma(\beta \mathbf{w}, \beta b) = \gamma(\mathbf{w}, b), \forall \beta \neq 0$



❖ اگر قدر مطلق $f(x)$ برای نزدیکترین نقطه به خط (SV) را با $\rho/2$ نشان دهیم، برای هر نمونه داده i داریم:

$$\begin{aligned} \mathbf{w}^T \mathbf{x}_i + b &\leq -\rho/2 & \text{if } y_i = -1 \\ \mathbf{w}^T \mathbf{x}_i + b &\geq \rho/2 & \text{if } y_i = 1 \end{aligned} \quad \Leftrightarrow \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq \rho/2$$

❖ برای بردارهای پشتیبان X (نزدیک‌ترین نمونه‌ها به خط جداکننده)، معادله بالا به صورت تساوی حاکم است.

❖ پارامترهای \mathbf{w} و b مقیاس پذیر هستند.

❖ اندازه آنها را طوری تغییر می‌دهیم که برای نزدیکترین نقطه به خط داشته باشیم: $|f(x)| = 1$

❖ با تغییر مقیاس پارامترهای \mathbf{w} و b با $\rho/2$ (تقسیم دو طرف نامعادله فوق بر $\rho/2$)، فاصله هر بردار پشتیبان X با خط (ابرفاصله) جداکننده خواهد بود:

$$r = \frac{y_s(\mathbf{w}^T \mathbf{x}_s + b)}{\|\mathbf{w}\|} = \frac{1}{\|\mathbf{w}\|}$$

❖ بدین صورت اندازه حاشیه نسبت عکس با اندازه \mathbf{w} خواهد داشت:

$$\rho = 2r = \frac{2}{\|\mathbf{w}\|}$$

راه حل یافتن خط جدا کننده

Minimise $||\mathbf{w}'||^2$

Subject to : $y_i (<\mathbf{w}', \mathbf{x}_i> + \mathbf{b}) \geq 1$ for all i

Where $||\mathbf{w}'||^2 = \mathbf{w}'^T \mathbf{w}'$

❖ این یک مسئله quadratic programming با محدودیت هائی بصورت نامعادلات خطی است.

❖ روش های شناخته شده ای برای چنین مسئله ای وجود دارد.

❖ حل معادله زیر متناظر با حل معادله بالا است و میتواند مقدار W را نتیجه دهد:

$$\text{maximise : } W(\alpha) = -\frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i \mathbf{x}_j + \sum_{i=1}^N \alpha_i$$

$$\text{subject to : } \sum_{i=1}^N \alpha_i y_i = 0, \alpha_i \geq 0, i = 1, \dots, N$$

$$\mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$$

❖ در این صورت W خواهد بود:

❖ \mathbf{b} به صورت مجزا محاسبه می شود (از معادله اولیه)

راه حل یافتن خط جدا کننده

$$\text{maximise : } W(\alpha) = -\frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i \mathbf{x}_j + \sum_{i=1}^N \alpha_i$$

$$\text{subject to : } \sum_{i=1}^N \alpha_i y_i = 0, \alpha_i \geq 0, i = 1, \dots, N$$

$$w = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i = \sum_{i \in SV} \alpha_i y_i \mathbf{x}_i$$

❖ معادله فوق محدب است ← یک جواب سرتاسری یکتا دارد که به راحتی پیدا می شود.

❖ داده ها در معادله فوق صرفا به صورت ضرب داخلی بین جفت نمونه ها حاضر شده اند.

❖ خوب؟

❖ خوب که خوب! یه دقیقه صب کن!

❖ حتی خود ابر صفحه جدا کننده هم به صورت ضرب داخلی جفت نمونه ها قابل بیان است:

$$f(\mathbf{x}, \alpha^*, b^*) = \mathbf{w}^* \mathbf{x} + b^* = \sum_{i=1}^N \alpha_i^* y_i \mathbf{x}_i \mathbf{x} + b^* = \sum_{i \in SV} \alpha_i^* y_i \mathbf{x}_i \mathbf{x} + b^*$$


❖ α_i ها برای همه نمونه ها غیر از بردارهای پشتیبان صفر هستند.

❖ تعداد بردارهای پشتیبان (SV) نسبت به کل داده ها بسیار کمتر است ← کوچک بودن مدل

❖ برای داده جدید، ضرب داخلیش با تمام SV ها باید محاسبه شود و علامت تابع f فوق، تعیین کننده دسته داده است.


داده هائی که بصورت خطی جدا پذیر نیستند (به دلیل نویز)

- ❖ یک فرض بسیار قوی در SVM این بود که داده‌ها بصورت خطی جداپذیر باشند. در حالیکه در عمل در بسیاری مواقع این فرض صحیح نیست.
- ❖ مثلاً به دلیل وجود نویز و تناقض در داده‌های آموزشی



افزودن متغیرهای slack

- ❖ یک راه حل این است که اندکی کوتاه آمده و مقداری خطا در دسته بندی را بپذیریم!
- ❖ این کار با معرفی متغیر ξ انجام می شود که نشانگر میزان خطا در ارزیابی برخی از نمونه ها توسط تابع $\mathbf{w}^T \mathbf{x} + b$ می باشد.



افزودن متغیر های slack

❖ با معرفی متغیر $\xi_i, i=1, 2, \dots, N$ محدودیت های قبلی ساده تر شده و رابطه

$$y_i (<w, x_i> + b) \geq 1$$

❖ بصورت زیر تغییر می کند:

$$y_i (<w, x_i> + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

❖ در حالت ایده آل همه این متغیرهای ξ_i باید صفر باشند.

❖ در این صورت مسئله بهینه سازی تبدیل می شود به یافتن w به نحوی که معادله زیر کمینه گردد:

$$\|w\|^2 + C \sum_i \xi_i^2$$


$$\text{subject to: } y_i (w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad \forall i$$

❖ که در آن $C > 0$ می باشد.

❖ جمله اضافه شده در تابع هدف سعی دارد تا حد امکان همه متغیرهای slack را کوچک نماید.

❖ مقدار مناسب پارامتر C ، بر اساس داده ها و میزان نویزی بودن آن ها و با آزمون و خطا باید پیدا شود (مهم)

داده هائی که بصورت خطی جدا پذیر نیستند (ذاتی)



❖ نگاشت داده‌ها به فضایی دیگر (فضای ویژگی) با کمک تابع $\phi(x)$ که در آن فضا داده‌ها به صورت خطی جداپذیرند


❖ اگر ابعاد فضای جدید به اندازه کافی بزرگ باشد، داده‌ها اغلب به صورت خطی جداپذیر خواهند بود.

❖ انجام محاسبات در فضای ویژگی می‌تواند پرهزینه باشد، زیرا ابعاد بیشتری دارد.

❖ در حالت کلی ابعاد این فضا بی‌نهایت است.

❖ برای غلبه بر این مشکل از ترفند هسته (kernel trick) استفاده می‌شود.

داده هائی که بصورت خطی جدا پذیر نیستند (ذاتی)



❖ نگاشت داده‌ها به فضایی دیگر (فضای ویژگی) با کمک تابع $\phi(x)$ که در آن فضا داده‌ها به صورت خطی جداپذیرند

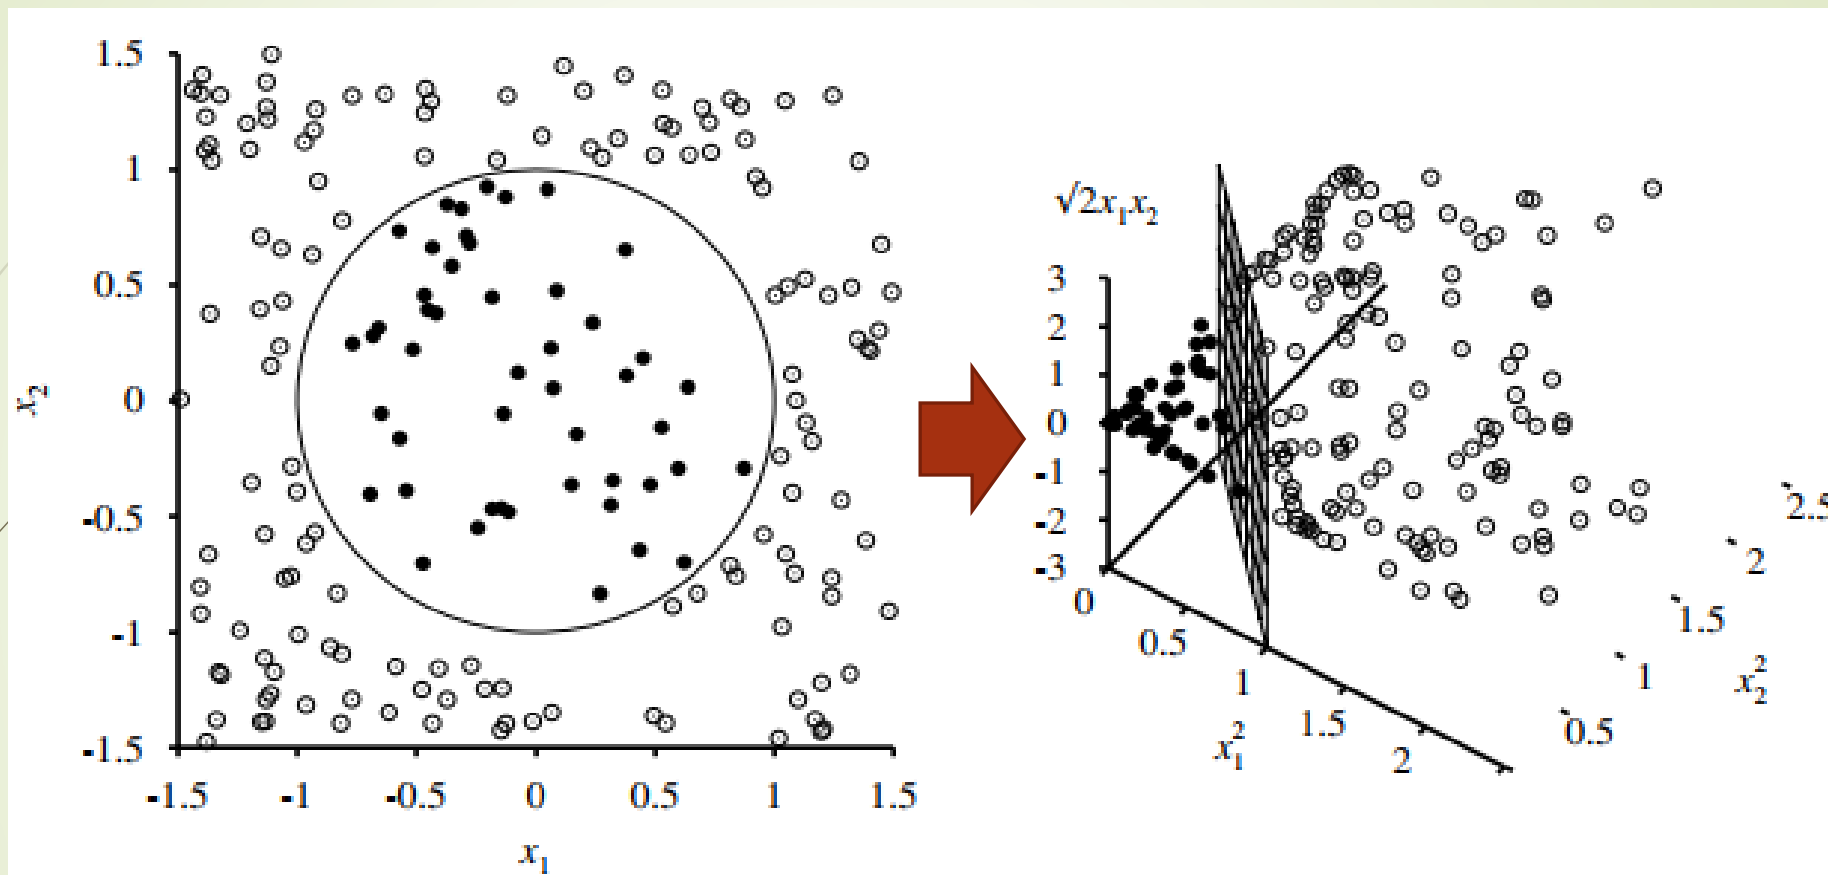
❖ اگر ابعاد فضای جدید به اندازه کافی بزرگ باشد، داده‌ها اغلب به صورت خطی جداپذیر خواهند بود.

❖ انجام محاسبات در فضای ویژگی میتواند پرهزینه باشد، زیرا ابعاد بیشتری دارد.

❖ در حالت کلی ابعاد این فضا بی‌نهایت است.

❖ برای غلبه بر این مشکل از ترفند هسته (kernel trick) استفاده می‌شود.

آیا نگاشت می‌تواند سودمند باشد؟



$$x = (x_1, x_2) \longrightarrow \phi(x) = (x_1^2, x_2^2, \sqrt{2}x_1x_2)$$

آیا در مثال فوق، با فضای نگاشت دارای ابعاد کمتر هم می‌توان دسته‌بندی خطی داشت؟

تعمیم SVM به حالت غیر خطی

❖ با داشتن $\phi(x)$ ، کافی است در مساله بهینه‌سازی SVM (مدل زیر)، به جای x ها، $\phi(x)$ قرار داد.

$$\text{maximise: } W(\alpha) = -\frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i \mathbf{x}_j + \sum_{i=1}^N \alpha_i$$

$$\text{subject to: } \sum_{i=1}^N \alpha_i y_i = 0, \alpha_i \geq 0, i = 1, \dots, N$$

❖ اما تابع نگاشت $\phi(x)$ را چگونه می‌توان یافت؟

❖ یافتن آن برای خطی کردن فضای داده‌ها می‌تواند بسیار دشوار و یا غیر ممکن باشد.

❖ اما جایگذاری $\phi(x_i) \cdot \phi(x_j)$ به جای $x_i \cdot x_j$ در مساله فوق، دست‌آورد مهمی در پی دارد!

❖ برای محاسبه $\phi(x_i) \cdot \phi(x_j)$ لازم نیست $\phi(x_i)$ و $\phi(x_j)$ ابتدا به صورت جداگانه محاسبه شوند.

❖ مثلاً در مثال اسلاید قبل، می‌توان به سادگی نشان داد:

$$\phi(x_i) \cdot \phi(x_j) = (x_i \cdot x_j)^2$$

❖ یعنی در مثال فوق، بدون داشتن تابع $\phi(x)$ (با خروجی ۳ بعدی مشخص) و صرفاً با جایگذاری $(x_i \cdot x_j)^2$

به جای $x_i \cdot x_j$ در تابع هدف SVM، داده‌های ذاتاً غیرخطی، به صورت خطی جداپذیر می‌شوند.

❖ آیا هنوز هم ایمان نمی‌آورید؟ پس همانا قومی ستم‌پیشه هستید!

تابع هسته


❖ در مثال فوق، تابع $(x_i \cdot x_j)^2$ ، تابع هسته (Kernel Function) نام دارد.

❖ تابع هسته به صورت $K(x_i \cdot x_j)$ نوشته می شود.

❖ دو بردار را می گیرد و عددی حقیقی (که می تواند بیانگر نوعی شباهت بین جفت نمونه های ورودی باشد) را برمی گرداند.

❖ تابع هسته روی جفت نمونه ها اعمال می شود و بیانگر ضرب داخلی دو نقطه در فضای نگاشت است.

❖ ضرب داخلی، معیاری است که بیانگر میزان شباهت دو نقطه (دو نمونه داده) است.



$$\mathbf{a} \cdot \mathbf{b} = |\mathbf{a}| |\mathbf{b}| \cos \theta$$

ترفند هسته

❖ با جایگذاری تابع هسته به جای ضرب داخلی جفت نمونه‌ها در محاسبات SVM، از تعریف صریح فضای نگاشت بی‌نیاز می‌شویم!

❖ در ریاضیات SVM، هم در یافتن خط جداکننده (فاز آموزش) و هم در مرحله آزمایش، از ضرب داخلی بین جفت نمونه‌ها استفاده شده است و هیچ x_i ای به صورت مستقل (بدون ضرب داخلی) وجود ندارد.

❖ بنابراین جایگذاری ضرب‌های داخلی با تابع هسته، کافی است.

❖ فاز آموزش:

$$\text{maximise: } W(\alpha) = -\frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i \mathbf{x}_j + \sum_{i=1}^N \alpha_i$$

$$\text{subject to: } \sum_{i=1}^N \alpha_i y_i = 0, \alpha_i \geq 0, i = 1, \dots, N$$

❖ فاز آزمایش (استفاده از علامت خروجی تابع f):

$$f(\mathbf{x}, \alpha^*, b^*) = \mathbf{w}^* \mathbf{x} + b^* = \sum_{i=1}^N \alpha_i^* y_i \mathbf{x}_i \mathbf{x} + b^* = \sum_{i \in SV} \alpha_i^* y_i \mathbf{x}_i \mathbf{x} + b^*$$

تعریف تابع هسته

❖ طبق تئوری Mercer در ریاضیات، هر تابع هسته‌ای که شرایط mercer را ارضا کند، متناظر با یک فضای ویژگی خواهد بود.

❖ وجود فضای ویژگی برای آن تابع هسته تضمین می‌شود.

❖ فضای ویژگی می‌تواند دارای ابعاد بسیار زیاد باشد، حتی اگر تابع هسته در ظاهر ساده باشد.

❖ تابع $k : X \times X \rightarrow R$ را هسته نامیده می‌شود اگر:

❖ متقارن باشد: $k(x,y) = k(y,x)$

❖ ماتریس K (موسوم به Gram matrix) حاصل از تابع k positive semi-definite باشد.

یعنی برای هر m نقطه دلخواه در فضا، ماتریس K با درایه‌های $k_{i,j} = k(x_i, x_j)$ در رابطه زیر صدق کند:

$$\forall c \in R^m, c^T K c \geq 0$$

مثال‌هایی از توابع هسته

❖ تابع هسته خطی:

$$k(x, y) = x^T y + c$$

❖ تابع هسته چند جمله‌ای:

$$K(\mathbf{x}_j, \mathbf{x}_k) = (1 + \mathbf{x}_j \cdot \mathbf{x}_k)^d$$

❖ متناظر با فضای ویژگی که ابعادش برحسب d نمایی است!

❖ و در حالت کلی‌تر:

$$k(x, y) = (\alpha x^T y + c)^d$$

❖ تابع هسته گاوسی یا RBF (Radial Basis Function):

$$k(x, y) = \exp \left(-\frac{\|x - y\|^2}{2\sigma^2} \right)$$

❖ کاربردی و مشهورترین

ساختن توابع هسته پیچیده‌تر

❖ اگر k و k' یک تابع هسته باشد:

❖ $k + k'$ نیز یک تابع هسته است


❖ ck برای $c > 0$ یک تابع هسته است

❖ $ak + bk'$ برای $a, b > 0$ یک تابع هسته است.

❖ ...


❖ بدین ترتیب می‌توان توابع پیچیده‌تر را با ترکیب توابع ساده‌تر ایجاد کرد.

خط جدا کننده در فضای ویژگی منحنی متناظر در فضای اولیه












Data in Original Space





Feature Space



Feature Space (Top View)





چند نکته تستی (!)

- ❖ توجه به پارامتر C (اهمیت متغیرهای slack)
- ❖ توجه به پارامترهای تابع هسته انتخاب شده
- ❖ نرمال سازی داده‌ها قبل از آموزش SVM
- ❖ مثلاً میانگین و واریانس (انحراف معیار) هر ویژگی در داده‌ها محاسبه شود و کلیه ویژگی‌ها منهای میانگین و تقسیم بر انحراف معیار شوند.
- ❖ استفاده از توابع هسته مختلف

ترفند هسته در غیر SVM

❖ هم کاربرد دارد (!)

❖ بسیاری از روش‌ها و الگوریتم‌های مطرح در حوزه هوش مصنوعی، از جمله دسته‌بندی کننده‌های مختلف، با استفاده از ترفند هسته، به حالت غیرخطی تعمیم داده می‌شوند.

❖ شرط اعمال ترفند هسته در هر مساله و روش ریاضیاتی، وجود ضرب داخلی بین جفت نمونه‌ها در روابط مربوطه و عدم استفاده از نمونه‌های ورودی خارج از ضرب داخلی در ریاضیات مساله است.

❖ برای اعمال ترفند هسته، نوعاً لازم است ریاضیات روش‌ها به گونه‌ای بازنویسی / بازتولید شود که ویژگی فوق در آن پدید آید.

❖ ← نسخه هسته‌ای روش‌های موجود