



دانشگاه علم و صنعت ایران
دانشکده مهندسی کامپیوتر

کمی سازی عدم قطعیت

«هوش مصنوعی: رهیافتی نوین»، فصل ۱۳

مدرس: آرش عبدی هجراندوست

نیم سال دوم ۱۴۰۱-۱۴۰۲

عدم قطعیت

❖ در منطق گزاره ها، امور، قطعی فرض می شدند.

❖ گاهی به دلایل مختلف، قطعیت وجود ندارد.

❖ احتمالات

❖ چگونه می توان از گزاره های احتمالا/تاحدودی درست استفاده کرد؟

یک مثال

❖ دستگاه تشخیص سرطان:

❖ احتمال داشتن سرطان در افراد 0.001 است.

❖ اگر سرطان باشد، با احتمال 0.99 نتیجه تست مثبت است.

❖ اگر سرطان نباشد، با احتمال 0.995 نتیجه تست منفی است.

❖ فرض کنید نتیجه تست شما مثبت شده:

❖ چقدر احتمال دارد سرطان داشته باشید؟

❖ زیر 0.50

❖ بین 0.50 تا 0.80

❖ بین 0.80 تا 0.95

❖ بالای 0.95

تئوری تصمیم

- ❖ یک عامل منطقی وقتی با پدیده‌های غیر قطعی مواجه است، چگونه باید تصمیم بگیرد؟
- ❖ چگونه باید بین پدیده‌ها ترجیح دهد؟
- ❖ طبق تئوری تصمیم، یک عامل منطقی است اگر و فقط اگر عملی را انتخاب کند که **بیشترین سودمندی مورد انتظار** را در پی دارد
- ❖ سودمندی مورد انتظار
- ❖ میانگین سودمندی برای خروجی‌های مختلف هر عمل
- ❖ میانگین وزن دار بر اساس احتمال وقوع هر خروجی
- ❖ مثال دیوانه و عقرب

تعاریف اولیه احتمال

- ❖ مجموع احتمالات برای تمام خروجی های یک متغیر تصادفی ۱ است
- ❖ احتمال، عددی نامنفی است.
- ❖ احتمالاتی نظیر $P(X)$ احتمال غیر شرطی یا احتمال اولیه یا prior نام دارند.
- ❖ میزان باور به وقوع پدیده‌ای وقتی هیچ اطلاعات دیگری در دست نیست.
- ❖ وقتی اطلاعات اضافی وجود دارد، احتمال $P(X | Y)$ را احتمال شرطی یا پسین یا posterior می‌نامیم.
- ❖ قانون شرطی:

$$P(a | b) = \frac{P(a \wedge b)}{P(b)}$$

❖ هر متغیر تصادفی یک دامنه (مقادیر ممکن) دارد.

❖ احتمال هر مقدار از دامنه:

$$P(\text{Weather} = \text{sunny}) = 0.6$$

$$P(\text{Weather} = \text{rain}) = 0.1$$

$$P(\text{Weather} = \text{cloudy}) = 0.29$$

$$P(\text{Weather} = \text{snow}) = 0.01 ,$$

❖ و برای سادگی:

$$\mathbf{P}(\text{Weather}) = \langle 0.6, 0.1, 0.29, 0.01 \rangle$$

\mathbf{P} = توزیع احتمال برای متغیر تصادفی Weather

❖ $\mathbf{P}(X | Y)$ = توزیع احتمال شرطی (برای مقادیر ممکن X و Y)

احتمال و متغیر پیوسته

❖ تابع توزیع احتمال برای متغیر پیوسته نمی‌تواند تمام مقادیر ممکن را برشمرد
❖ بی نهایت مقدار وجود دارد

❖ در این حالت احتمال متغیر تصادفی X را با تابعی پارامتردار/پیوسته برحسب X نشان می‌دهیم.

❖ مثلاً: $P(\text{NoonTemp}=x) = \text{Uniform}_{[18C, 26C]}(x)$

❖ دما دارای توزیع یکنواخت بین بازه ۱۸ تا ۲۶ درجه است.

❖ به تابع مذکور، تابع چگالی احتمال probability density function – pdf می‌گوییم.

تابع چگالی احتمال

❖ تابع چگالی احتمال معنای متفاوتی نسبت به تابع توزیع احتمال گسسته دارد.

❖ احتمال آنکه دما در زمانی معین، دقیقاً ۲۰ درجه باشد؟ صفر

❖ حتی اگر باشد هم ابزار دقیقی که بسنجد این واقعیت را نداریم.

❖ تمامی percept های تجربی ما از مفاهیم پیوسته دنیا، نادقیق است و ما هیچ چیزی از دنیا را دقیق نمی‌دانیم!

❖ آیا چنین است؟

❖ معنای شهودی $P(X=x)$ یا $P(x)$ (تابع چگالی احتمال)

❖ احتمال آنکه متغیر X در بازه‌ای کوچک در اطراف x بیفتد، تقسیم بر طول بازه مذکور

$$P(x) = \lim_{dx \rightarrow 0} P(x \leq X \leq x + dx) / dx$$

$$P(\text{NoonTemp} = x) = \text{Uniform}_{[18C, 26C]}(x) = \begin{cases} \frac{1}{8C} & \text{if } 18C \leq x \leq 26C \\ 0 & \text{otherwise} \end{cases}$$


❖ احتمال آنکه دما ۲۰.۱۸ باشد = صفر

$$P(\text{NoonTemp} = 20.18) = 1/8C \quad \text{❖}$$

$$\diamond P(x) = \frac{P(x \leq X \leq x + dx)}{dx}$$

$$\diamond P(x) \cdot dx = P(x \leq X \leq x + dx)$$

♦ مساحت زیر نمودار = ۱



احتمال توام

❖ توزیع احتمال چند متغیر تصادفی

❖ $P(X, Y)$ = احتمال تمام ترکیب‌های ممکن برای مقادیر X و Y

❖ احتمال توام را می‌توان بدین شکل نوشت:

$$P(X, Y) = P(X | Y) \cdot P(Y) \quad \text{❖}$$

❖ احتمال توام کامل: احتمال برای تمام متغیرهای موجود (بدون در نظر نگرفتن هیچ متغیری)

منشا احتمال

❖ مناقشه بر سر اینکه منشا احتمال چیست:

❖ نگاه فراوانی محور:

❖ احتمال از روی آزمایش و تجربه به دست می‌آید و بر اساس فراوانی مشاهدات

❖ نگاه عینیت‌گرا:

❖ احتمالات، مفاهیمی واقعی مربوط به دنیا هستند (جنبه‌هایی از دنیای واقعی هستند) که عبارت است از گرایش ذاتی اشیاء به داشتن یک رفتار (خروجی) خاص.

❖ احتمال، صرفاً توصیفی از میزان باور مشاهده کننده خارجی نسبت به اشیاء نیست.

❖ نگاه ذهنیت‌گرا:

❖ احتمال راهی برای بیان باور مشاهده کننده است نسبت به یک پدیده، بی آنکه معنا و مفهوم فیزیکی خارجی برای آن متصور باشد.

❖ بحث:

❖ احتمال آمدن خط در پرتاب سکه ۰.۵ است. (یعنی چه؟)

❖ احتمال بارندگی فردا ۰.۷ است؟

❖ نگاه فراوانی محور: اگر ۱۰۰ بار فردا بشود در شرایطی که دقیقا امروز حاکم است، ۷۰ بارش باران می بارد؟

❖ چنین آزمایشی امکان پذیر است؟ قبلا تجربه شده است؟

❖ به احتمال ۰.۸۵ تیم ایران از گروه خود صعود نخواهد کرد!

❖ قبلا شرایط مشابه تجربه شده؟ نگاه فراوانی محور؟ عینیت گرا؟ ذهنیت گرا؟

❖ آیا در پرتاب سکه، عنصر تصادف وجود دارد؟ (متغیر تصادفی؟)

استنتاج با توزیع توام کامل

- ❖ استنتاج احتمالاتی: یافتن احتمال پسین برای گزاره‌های پرسش شده با پدیده‌های مشاهده شده
- ❖ با توزیع توام کامل به عنوان پایگاه دانش می‌توان پاسخ هر پرسشی را داد.
- ❖ فرض کنیم ۳ متغیر بولین داریم: دندان درد، کرم‌خوردگی دندان، گیرکردن میله دندانپزشک در دندان
- ❖ توزیع توام کامل:

	<i>toothache</i>		\neg <i>toothache</i>	
	<i>catch</i>	\neg <i>catch</i>	<i>catch</i>	\neg <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
\neg <i>cavity</i>	0.016	0.064	0.144	0.576

	<i>toothache</i>		\neg <i>toothache</i>	
	<i>catch</i>	\neg <i>catch</i>	<i>catch</i>	\neg <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
\neg <i>cavity</i>	0.016	0.064	0.144	0.576

$$P(\text{cavity} \vee \text{toothache}) = 0.108 + 0.012 + 0.072 + 0.008 + 0.016 + 0.064 = 0.28$$

❖ احتمال حاشیه‌ای - Marginal Probability

$$P(\text{cavity}) = 0.108 + 0.012 + 0.072 + 0.008 = 0.2$$

❖ حاشیه‌سازی (!) - Marginalization

$$\mathbf{P}(\mathbf{Y}) = \sum_{\mathbf{z} \in \mathbf{Z}} \mathbf{P}(\mathbf{Y}, \mathbf{z})$$

$$\mathbf{P}(\mathbf{Y}) = \sum_{\mathbf{z}} \mathbf{P}(\mathbf{Y} | \mathbf{z}) P(\mathbf{z})$$

❖ شرطی سازی:

مثال استنتاج شرطی

	<i>toothache</i>		\neg <i>toothache</i>	
	<i>catch</i>	\neg <i>catch</i>	<i>catch</i>	\neg <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
\neg <i>cavity</i>	0.016	0.064	0.144	0.576

$$P(cavity | toothache) = \frac{P(cavity \wedge toothache)}{P(toothache)}$$

$$= \frac{0.108 + 0.012}{0.108 + 0.012 + 0.016 + 0.064} = 0.6$$

$$P(\neg cavity | toothache) = \frac{P(\neg cavity \wedge toothache)}{P(toothache)}$$

$$= \frac{0.016 + 0.064}{0.108 + 0.012 + 0.016 + 0.064} = 0.4$$

❖ مخرج کسر نقش نرمال سازی را بازی می کند (جمع دو احتمال فوق را یک می کند)

$$\mathbf{P}(Cavity | toothache) = \alpha \mathbf{P}(Cavity, toothache)$$

$$= \alpha [\mathbf{P}(Cavity, toothache, catch) + \mathbf{P}(Cavity, toothache, \neg catch)]$$

$$= \alpha [\langle 0.108, 0.016 \rangle + \langle 0.012, 0.064 \rangle] = \alpha \langle 0.12, 0.08 \rangle = \langle 0.6, 0.4 \rangle .$$

❖ $Cavity$ = متغیر بولین (هر دو مقدار ممکن)

❖ $cavity$ = مقدار true برای متغیر $Cavity$ (کرم خوردگی داشتن دندان)

استقلال

❖ اگر در مثال دندانپزشک، متغیر چهارمی به نام «وضعیت هوا» هم اضافه شود...

$$\begin{aligned} &P(\text{toothache}, \text{catch}, \text{cavity}, \text{cloudy}) \\ &= P(\text{cloudy} \mid \text{toothache}, \text{catch}, \text{cavity})P(\text{toothache}, \text{catch}, \text{cavity}) \end{aligned}$$

$$P(\text{cloudy} \mid \text{toothache}, \text{catch}, \text{cavity}) = P(\text{cloudy})$$

$$P(\text{toothache}, \text{catch}, \text{cavity}, \text{cloudy}) = P(\text{cloudy})P(\text{toothache}, \text{catch}, \text{cavity})$$

$$\mathbf{P}(\text{Toothache}, \text{Catch}, \text{Cavity}, \text{Weather}) = \mathbf{P}(\text{Toothache}, \text{Catch}, \text{Cavity})\mathbf{P}(\text{Weather})$$

❖ و در حالت کلی برای گزاره های a, b یا متغیرهای مستقل تصادفی X, Y داریم:

$$P(a \mid b) = P(a) \quad \text{or} \quad P(b \mid a) = P(b) \quad \text{or} \quad P(a \wedge b) = P(a)P(b)$$

$$\mathbf{P}(X \mid Y) = \mathbf{P}(X) \quad \text{or} \quad \mathbf{P}(Y \mid X) = \mathbf{P}(Y) \quad \text{or} \quad \mathbf{P}(X, Y) = \mathbf{P}(X)\mathbf{P}(Y)$$

قاعده بیز (Bayes)

$$P(a \wedge b) = P(a | b)P(b)$$

$$P(a \wedge b) = P(b | a)P(a)$$

$$P(b | a) = \frac{P(a | b)P(b)}{P(a)}$$

❖ قاعده بیز:

$$\mathbf{P}(Y | X) = \frac{\mathbf{P}(X | Y)\mathbf{P}(Y)}{\mathbf{P}(X)}$$

❖ و در حالت کلی:

❖ اگر یک مشاهده زمینه‌ای Θ داشته باشیم:

$$\mathbf{P}(Y | X, \mathbf{e}) = \frac{\mathbf{P}(X | Y, \mathbf{e})\mathbf{P}(Y | \mathbf{e})}{\mathbf{P}(X | \mathbf{e})}$$

کاربرد قاعده بیز

$$P(b|a) = \frac{P(a|b)P(b)}{P(a)}$$

❖ در نگاه اول، قاعده بیز، یک عبارت را بر حسب سه عبارت دیگر که پیچیدگی یکی از آنها در حد پیچیدگی عبارت اول است بیان می کند.

❖ چرا باید کاربردی باشد؟

❖ اگر از این زاویه به مساله نگاه کنیم، قدری متفاوت است:

$$P(cause | effect) = \frac{P(effect | cause)P(cause)}{P(effect)}$$

❖ $P(effect|cause)$: زاویه دید علی (Causal)

❖ $P(cause|effect)$: زاویه دید تشخیصی (Diagnostic)

❖ اطلاعات در سمت راست معادله فوق، ارزان تر از اطلاع سمت چپ به دست می آیند!

کاربرد قاعده بیز

- ❖ پزشک می‌داند بیماری مننژیت (m) در ۷۰٪ موارد باعث سفتی گردن (s) می‌شود.
- ❖ پزشک می‌داند احتمال داشتن مننژیت در مردم ۱/۵۰۰۰۰ است.
- ❖ (پزشک می‌داند ۱٪ مردم دچار سفتی گردن هستند).
- ❖ مراجعه کننده با عارضه سفتی گردن مراجعه کرده است:

$$P(s | m) = 0.7$$

$$P(m) = 1/50000$$

$$P(s) = 0.01$$

$$P(m | s) = \frac{P(s | m)P(m)}{P(s)} = \frac{0.7 \times 1/50000}{0.01} = 0.0014$$

❖ اگر نرمال سازی که قبلا اشاره شد را در اینجا به کار بگیریم:

$$\mathbf{P}(M | s) = \alpha \langle P(s | m)P(m), P(s | \neg m)P(\neg m) \rangle$$

❖ در این صورت به جای دانستن $P(s)$ باید $P(s | \neg m)$ را بدانیم.

❖ جمع $P(s|m)P(m) + P(s|\neg m)P(\neg m)$ که برابر با معکوس α است، $P(s)$ را تشکیل می دهد.

❖ در عمل گاهی اولی ارزان تر/در دسترس است و گاهی دومی.

❖ شکل کلی قاعده بیز با نرمال سازی:

$$\mathbf{P}(Y | X) = \alpha \mathbf{P}(X | Y)\mathbf{P}(Y)$$

چرا قاعده بیز کاربردی است؟

- ❖ دلیل اول: ارزان تر بودن و دسترسی بیشتر به اطلاعات علی نسبت به اطلاعات تشخیصی
- ❖ دلیل دوم: اطلاعات تشخیصی حتی در صورت موجود بودن، شکننده هستند.
- ❖ اگر در اثر یک اپیدمی، بیماری مننژیت گسترش یابد، احتمال پیشین $P(m)$ افزایش می یابد.
- ❖ در این صورت پزشکی که $P(m | s)$ را بر اساس اطلاعات آماری گذشته خود (یا کتاب خود) می دانسته، چگونه باید آن را به روز کند؟
- ❖ در انتظار نسخه بعدی کتاب؟ یا جمع آوری دوباره اطلاعات از افراد دارای سفتی گردن؟
- ❖ اما پزشکی که $P(m | s)$ را با قاعده بیز محاسبه کرده، می داند که این احتمال نسبت مستقیمی با $P(m)$ دارد.

استفاده از Bayes با چند مشاهده

❖ اطلاعات در مسیر علی معمولاً موجود است.

❖ در مسیر تشخیصی، اگر چند مشاهده (evidence) وجود داشته باشد:

❖ می‌توان با داشتن جدول توزیع توام احتمالات پاسخ را پیدا کرد:

$$\mathbf{P}(Cavity | toothache \wedge catch) = \alpha \langle 0.108, 0.016 \rangle \approx \langle 0.871, 0.129 \rangle$$

❖ اما داشتن جدولی بزرگ برای متغیرهای زیاد غیر ممکن/دشوار است.

❖ می‌توان از قاعده بیز استفاده کرد:

$$\begin{aligned} \mathbf{P}(Cavity | toothache \wedge catch) \\ = \alpha \mathbf{P}(toothache \wedge catch | Cavity) \mathbf{P}(Cavity) \end{aligned}$$

❖ اما لازم است احتمال شرطی ترکیب عطفی چند متغیر را بدانیم و با تعداد متغیر بالا فرض دانستن چنین اطلاعاتی به سختی داشتن جدول توزیع توام است.

❖ می‌توان از برخی از متغیرهای کم اهمیت‌تر صرف نظر کرد تا جوابی تقریبی ولی کم هزینه‌تر یافت!

❖ ایموجی مربوطه!

استفاده از Bayes با چند مشاهده

❖ آیا از مفهوم استقلال می‌توان استفاده کرد؟

$$\propto \mathbf{P}(\text{toothache} \wedge \text{catch} \mid \text{Cavity}) \mathbf{P}(\text{Cavity})$$

❖ آیا toothache و catch مستقلند؟

❖ اگر باشند، احتمال شرطی فوق به دو بخش ارزان خواهد شکست.

❖ اما مستقل نیستند!

❖ اگر میله دندانپزشک گیر کند، احتمال اینکه فرد دندان درد هم داشته باشد بیشتر می‌شود و برعکس

❖ در جامعه آماری دندان دردنده‌ها(!)، فراوانی گیرنده(!)های میله پزشکی بیشتر است نسبت به جامعه آماری نرمال

❖ toothache و catch مستقلند، اگر وضعیت Cavity را بدانیم!

❖ هر دو متغیر مستقیمی از یک ریشه مشترک تاثیر می‌گیرند، بی آنکه تاثیر مستقیمی روی هم بگذارند.

❖ دندان درد مستقیمی از وضعیت عصب‌های دندان اثر می‌گیرد و گیر کردن میله تابع مهارت دندانپزشک است.

$$\mathbf{P}(\text{toothache} \wedge \text{catch} \mid \text{Cavity}) = \mathbf{P}(\text{toothache} \mid \text{Cavity}) \mathbf{P}(\text{catch} \mid \text{Cavity})$$

❖ این دو متغیر نسبت به هم دارای استقلال شرطی هستند.

استقلال شرطی

❖ دو متغیر X و Y دارای استقلال شرطی هستند:

$$P(X, Y | Z) = P(X | Z)P(Y | Z)$$

$$P(X | Y, Z) = P(X | Z) \quad \text{and} \quad P(Y | X, Z) = P(Y | Z)$$

❖ بیان آماری استقلال شرطی:

❖ در یک جامعه آماری ۱۰۰ نفره، همه افراد دارای کرم خوردگی دندان (به یک اندازه ثابت) هستند

❖ ۳۰٪ دندان درد دارند

❖ ۴۰٪ catch=true هستند

❖ هم بستگی بین این ۳۰ نفر و آن ۴۰ نفر؟

❖ اگر آن ۴۰ نفر را جدا کنیم، آیا می‌توان گفت در بین آنها شیوع دندان درد بیشتر یا کمتر از ۳۰٪ است؟

❖ خیر ← استقلال شرطی

استفاده از استقلال شرطی و قاعده بیز

❖ دندانپزشک لازم دارد بداند احتمال کرم خوردگی (و نیاز به ترمیم) با چند مشاهده مختلف چقدر است؟

❖ ۵ متغیر، مثلاً درد+رادیولوژی+مسواک میزنه یا نه+رژیم غذایی بد داره یا نه +... ۳۲ حالت مختلف

❖ جدول کامل احتمالات توام را نمی توان داشت

❖ با قاعده بیز، احتمال کرم خوردگی از بقیه احتمالات جدا می شود (مقدارش را داریم)

❖ احتمال توام بقیه متغیرها به دلیل استقلال شرطی شان، حاصل ضرب احتمال تک تک متغیرها به شرط ریشه است

❖ احتمال تک تک متغیرها به شرط ریشه را به راحتی می توان در گوگل هم پیدا کرد!

❖ این جزء شناسنامه یک بیماری است که چند درصد باعث بروز فلان علامت میشود و چند درصد بهمان علامت.

میزان کاهش هزینه

- ❖ با ۳ متغیر تصادفی دودوئی (شامل ریشه)، در جدول توزیع احتمال، هشت عدد (احتمال) وجود دارد که جمعشان ۱ است
- ❖ بنابراین، عملاً هفت عدد مستقل وجود دارد.
- ❖ با استفاده از استقلال شرطی و قاعده بیز:
- ❖ یک عدد مستقل برای ریشه (کرم خوردگی) داریم. (جمع احتمال کرم خوردگی و کرم ناخوردگی یک است ← یک عدد مستقل)
- ❖ یک عدد مستقل برای دندان درد با فرض وجود کرم خوردگی داریم (با این فرض، جمع احتمال داشتن و نداشتن دندان درد، یک است)
- ❖ یک عدد مستقل برای دندان درد با فرض عدم وجود کرم خوردگی داریم (با این فرض، جمع احتمال داشتن و نداشتن دندان درد، یک است)
- ❖ دو عدد مستقل دیگر به همین ترتیب برای catch مورد نیاز است.
- ❖ بنابراین اگر از استقلال شرطی استفاده نشود، $2^n - 1$ عدد احتمال نیاز است.
- ❖ رشد نمایی نیازمندی با افزایش تعداد متغیر
- ❖ اگر از استقلال شرطی و قاعده بیز استفاده شود $2n - 1$ عدد نیاز است
- ❖ رشد خطی نیازمندی با افزایش تعداد متغیر
- ❖ اگر متغیرها k مقدار مختلف داشته باشند (دودوئی نباشند) چطور؟

دسته‌بندی مبتنی بر بیز

❖ مدل بیز ساده انگارانه (Naive Bayes):

$$P(Cause, Effect_1, \dots, Effect_n) = P(Cause) \prod_i P(Effect_i | Cause)$$

❖ چرا ساده انگارانه:

❖ ممکن است effect ها واقعا دارای استقلال شرطی نباشند.

❖ به مدل فوق دسته‌بندی کننده بیز نیز گفته می‌شود.

❖ دسته بندی؟

❖ تعدادی effect دیده‌ایم. دسته خروجی (Cause) را میخواهیم تعیین کنیم.

$$P(Cause | Effect_1, \dots, Effect_n) = \alpha P(Cause, Effect_1, \dots, Effect_n) = \alpha P(Cause) \prod_i P(Effect_i | Cause)$$

❖ ضریب α اهمیتی ندارد، زیرا احتمال مقادیر مختلف برای Cause با یکدیگر مقایسه می‌شوند و مقدار با بیشترین احتمال، خروجی دسته‌بند خواهد بود.

❖ $P(Cause)$ به صورت آماری قابل تحصیل است.

❖ $P(Effect_i | Cause)$ نیز هم!

❖ این مدل با وجود ساده لوحی، در عمل کارایی خیلی خوبی دارد.

❖ یک مزیت مهم: کنار آمدن با Missed Value ها

❖ کافی است برای $m < n$ (یعنی برای value های موجود) مدل بالا را محاسبه کنیم: $P(Cause | Effect_1, \dots, Effect_m)$

❖ وقتی برخی ویژگی‌ها از یک نمونه موجود نیست، بسیاری از دسته‌بندها دچار مشکل می‌شوند